
Адаптивное условное диффузионное сэмплирование при поступлении новых наблюдений в процессе генерации

Adaptive Conditional Diffusion Sampling with Observations Arriving During Generation

Аннотация

Данная работа посвящена исследованию способов адаптации диффузионных моделей для генерации траекторий к условиям, когда новый контекст поступает во время генерации. В задачах прогнозирования движения дополнительные наблюдения могут уточнить возможные варианты будущего или существенно изменить их вероятности, однако учёт этих данных может потребовать повторных вычислений, которые не всегда допустимы при ограниченном времени и вычислительном бюджете. Я исследую, как обновлять формируемую траекторию с учётом новых данных, в каких случаях можно использовать уже выполненные вычисления и как выбранный способ обновления влияет на качество прогноза и затраты на его получение. Для этого я рассмотрю существующие подходы к диффузионному прогнозированию, потоковой генерации и условному сэмплированию, сопоставлю их предположения и ограничения и выделю способы, применимые к изменению контекста внутри незавершённого процесса генерации. Сравнение предполагается проводить при разных моментах поступления наблюдений, разной степени их влияния на прогноз и сопоставимых вычислительных бюджетах, учитывая точность траекторий, разнообразие возможных исходов и время получения обновлённого результата. При этом я отдельно рассмотрю качество вероятностного прогноза, поскольку близость одной сгенерированной траектории к наблюдаемому движению ещё не означает, что модель корректно отражает неопределённость будущего. На основе выявленных ограничений я предложу возможные способы улучшения существующих подходов и проверю, в каких условиях они позволяют эффективнее использовать новые наблюдения. Исследование направлено на определение возможностей и границ адаптации диффузионного сэмплирования к изменяющемуся контексту при ограниченных вычислительных ресурсах.

Ключевые слова: диффузионные модели; генерация траекторий; вероятностное прогнозирование; условное сэмплирование; потоковые наблюдения; вычислительная эффективность.

Abstract

This work investigates ways to adapt diffusion models for trajectory generation to settings where new context arrives during generation. In motion forecasting, additional observations can refine possible futures or substantially change their probabilities, but incorporating these data may require repeated computation that is not always feasible under limited time and computational budgets. I investigate how to update a trajectory being generated using new data, when previous computation can be reused, and how the update strategy affects forecast quality and computational cost. To this end, I will review existing approaches to diffusion forecasting, streaming generation, and conditional sampling, compare their assumptions and limitations, and identify strategies applicable to context changes within an unfinished generation process. The comparison will consider different observation arrival times, different degrees of influence on the forecast, and comparable computational budgets, assessing trajectory accuracy, diversity of possible outcomes, and the time required to produce an updated result. I will also examine probabilistic forecast quality, since a single generated trajectory being close to the observed motion does not necessarily mean that the model correctly represents uncertainty about the future. Based on the identified limitations, I will propose possible improvements and test the conditions under which they make more effective use of new observations. The investigation aims to establish the capabilities and limits of adapting diffusion sampling to changing context under limited computational resources.

Keywords: diffusion models; trajectory generation; probabilistic forecasting; conditional sampling; streaming observations; computational efficiency.

1 Обзор литературы

1.1 Диффузионная генерация и прогнозирование траекторий

Диффузионные модели формируют результат через последовательное расшумление. Базовая дискретная формулировка представлена в DDPM [1], а непрерывная связь между стохастическим процессом и дифференциальным уравнением — в Score-SDE [2]. Для моей темы важно, что между начальным шумом и готовой траекторией существует промежуточное состояние. При поступлении новых данных возникает вопрос, можно ли использовать это состояние для обновлённого прогноза и какие ошибки при этом появляются.

В прогнозировании движения MID использует историю траекторий и взаимодействия участников для условной генерации [3]. LED дополнительно обучает инициализацию, позволяющую пропускать часть расшумления [4], а MotionDiffuser моделирует совместные варианты движения нескольких участников и поддерживает направленное сэмплирование [5]. Эти работы дают предметную основу для сравнения качества, разнообразия и стоимости прогнозов. DiffTraj также работает с траекториями, но решает задачу генерации синтетических GPS-данных [6]. Поэтому я рассматриваю её как источник идей о представлении данных, а не как прямой аналог обновления прогноза.

Отдельную группу составляют методы планирования. Diffuser и Decision Diffuser используют условную генерацию для построения поведения с заданными целями и ограничениями [7], [8]. Diffusion Policy генерирует последовательности действий по наблюдениям [9]; Diffusion Planner рассматривает автономное движение [10], а DiffPhyCon — управление физическими системами [11]. Здесь качество определяется не только соответствием распределению данных, но и результатом исполнения выбранных действий. AdaptDiffuser дополнительно изменяет сам планировщик через дообучение на отобранных синтетических данных [12]. Я отделяю такую адаптацию модели от обновления одного незавершённого прогноза.

1.2 Новые наблюдения и повторное использование вычислений

Наиболее близки к теме работы, сохраняющие часть генерации между поступлениями данных. Streaming Diffusion Policy поддерживает буфер действий с разными уровнями шума и уточняет его по новым наблюдениям [13]. CL-DiffPhyCon также использует асинхронное расшумление, включая обратную связь при генерации дальнейших управляющих воздействий [14]. Они показывают, что использование нового контекста до завершения всей последовательности уже является самостоятельным направлением исследований. Diffusion Forcing даёт более общий механизм обучения последовательностей с разными уровнями шума у элементов [15].

RTI-DP использует ранее предсказанную последовательность как начальное приближение для следующего расчёта [16]. Sequential Flow Matching рассматривает перенос предыдущего распределения в обновлённое по наблюдениям [17]. В отличие от повторного использования отдельной траектории, здесь обучается переход между распределениями. Авторы последней работы отмечают накопление ошибок при рекурсивных обновлениях и обсуждают адаптивное повторное зашумление и перезапуск как дальнейшие направления. Это конкретная связь с моей темой, но не основание считать такую общую идею новой.

Задержку можно учитывать и на уровне исполнения. RTC согласует соседние фрагменты действий при асинхронной генерации [18]. Reactive Diffusion Policy выделяет быстрый контур обратной связи [19], а FA-RDP адаптирует частоту вывода и число шагов генерации к неоднозначности действий [20]. Эти подходы показывают, что реакция на новые данные может достигаться разными механизмами. Поэтому я буду различать обновление промежуточного сэмпла, перенос готового прогноза и коррекцию исполнения: близкие практические цели не делают эти задачи одинаковыми.

1.3 Условное распределение по наблюдениям

Для анализа обновлений полезны работы с временными рядами. CSDI и SSSD восстанавливают пропущенные значения по доступным наблюдениям [21], [22]. TimeGrad строит авторегрессионный прогноз [23], а TimeDiff генерирует будущий участок совместно и использует специальные механизмы задания условия [24]. TSDiff вводит условия при выводе и рассматривает уточнение готовых прогнозов [25]. Эти методы помогают выбрать основу для экспериментов, но применение к наблюдениям, поступающим внутри расшумления, требует собственного протокола.

Score-based Data Assimilation отделяет модель наблюдений от обучения генератора и восстанавливает траектории по неполным или шумным измерениям [26]. В обратных задачах похожую роль играют DDRM и Diffusion Posterior Sampling [27], [28]. Однако согласование с измерениями может опираться на приближения, а ограничения линейной модели наблюдений подходят не для любого контекста. Кроме того, Classifier-Free Guidance управляет соответствием условию и разнообразием [29]; усиление такого соответствия само по себе не подтверждает корректность вероятностного обновления.

1.4 Вычислительная эффективность и повторное зашумление

Сокращение затрат не обязательно связано с адаптацией контекста. DDIM, DPM-Solver, DPM-Solver++ и UniPC ускоряют численное сэмплирование [30], [31], [32], [33]. EDM систематизирует выбор параметризации, расписания шума и сэмплера [34]. Progressive Distillation и Consistency Models уменьшают число шагов через изменение обучения [35], [36], а Flow Matching представляет смежный способ обучать перенос распределений [37]. Эти работы нужны, чтобы отделить возможную пользу обновления контекста от обычного ускорения генератора и учитывать стоимость дополнительного обучения.

Повторное зашумление также является известным инструментом. RePaint использует повторное сэмплирование при восстановлении изображений [38], Restart исследует сочетание добавления шума и обратного интегрирования [39], а RePS переносит restart-подход на обратные задачи [40]. Их результаты обосновывают включение подобных операций в сравнение, но не устанавливают, какая коррекция нужна после конкретного нового наблюдения в задаче траекторий.

1.5 Направление исследования

Рассмотренные работы уже предлагают способы потоковой генерации, повторного использования прогнозов и ускорения сэмплирования. Поэтому я не формулирую задачу как создание первого метода, учитывающего новые наблюдения. Я исследую, как эти способы работают при изменении контекста внутри незавершённой генерации траектории и как их применимость зависит от момента поступления данных, величины изменения прогноза и доступного бюджета. Для сравнения важны и точность, и сохранение неопределённости, и время получения обновления. На основе выявленных ограничений я предложу возможные улучшения; конкретный подход и его отличие от ближайших методов будут определены по результатам дальнейшего анализа и экспериментов.

2 Related Work

2.1 Diffusion generation and trajectory forecasting

Diffusion models generate outputs through successive denoising. DDPM provides the basic discrete formulation [1], while Score-SDE relates stochastic processes and differential equations in continuous time [2]. For my topic, an important feature is the intermediate state between initial noise and a completed trajectory. When new data arrive, the question is whether this state can support an updated forecast and what errors this introduces.

In motion forecasting, MID conditions generation on trajectory history and interactions [3]. LED additionally learns an initialization that skips part of denoising [4], while Motion-Diffuser models joint multi-agent futures and supports guided sampling [5]. These studies provide a domain-specific basis for comparing forecast quality, diversity, and cost. DiffTraj also addresses trajectories but generates synthetic GPS data [6]. I therefore consider it a source of representation ideas rather than a direct analogue of forecast updating.

Planning methods form a separate group. Diffuser and Decision Diffuser use conditional generation to construct behavior with specified goals and constraints [7], [8]. Diffusion Policy generates action sequences from observations [9]; Diffusion Planner addresses autonomous driving [10], and DiffPhyCon addresses physical-system control [11]. Their quality depends on the outcome of executed actions as well as agreement with the data distribution. Adapt-Diffuser additionally changes the planner through fine-tuning on selected synthetic data [12]. I distinguish this model adaptation from updating a single unfinished forecast.

2.2 New observations and reuse of computation

The closest studies preserve part of generation across incoming observations. Streaming Diffusion Policy maintains an action buffer with different noise levels and refines it using new observations [13]. CL-DiffPhyCon similarly uses asynchronous denoising, incorporating feedback when generating subsequent controls [14]. They demonstrate that using new context before the full sequence is complete is already an established research direction. Diffusion Forcing provides a more general training mechanism for sequences with different noise levels per element [15].

RTI-DP uses a previously predicted sequence as the initial guess for the next computation [16]. Sequential Flow Matching transports the previous distribution to an updated one conditioned on observations [17]. Unlike reusing an individual trajectory, it learns a transition between distributions. Its authors identify error accumulation in recursive updates and discuss adaptive re-noising and resets as future directions. This directly connects to my topic but does not make the general idea novel.

Latency can also be addressed at execution time. RTC aligns adjacent action chunks under asynchronous generation [18]. Reactive Diffusion Policy introduces a fast feedback loop [19], while FA-RDP adapts inference frequency and sampling steps to action ambiguity [20]. These approaches demonstrate different mechanisms for responding to new data. I will therefore distinguish intermediate-sample updates, reuse of completed forecasts, and execution corrections: similar practical goals do not make these problems identical.

2.3 Conditional distributions from observations

Time-series studies provide useful foundations for analyzing updates. CSDI and SSSD impute missing values from available observations [21], [22]. TimeGrad produces autoregressive forecasts [23], while TimeDiff generates the future segment jointly with specialized conditioning mechanisms [24]. TSDiff introduces conditions at inference and considers refining existing forecasts [25]. These methods inform the choice of an experimental base, but observations arriving within denoising require a dedicated protocol.

Score-based Data Assimilation separates the observation model from generator training and reconstructs trajectories from incomplete or noisy measurements [26]. DDRM and Diffusion Posterior Sampling play related roles in inverse problems [27], [28]. However, measurement conditioning can rely on approximations, and linear observation assumptions do not cover every form of context. Classifier-Free Guidance controls condition adherence and diversity [29]; increasing adherence does not itself establish a correct probabilistic update.

2.4 Computational efficiency and re-noising

Reducing cost does not necessarily require context adaptation. DDIM, DPM-Solver, DPM-Solver++, and UniPC accelerate numerical sampling [30], [31], [32], [33]. EDM organizes choices of parameterization, noise scheduling, and sampling [34]. Progressive Distillation and Consistency Models reduce sampling steps through changes in training [35], [36], while Flow Matching provides an adjacent approach to learning distribution transport [37]. These studies help separate the potential benefit of context updating from ordinary generator acceleration and account for additional training costs.

Re-noising is also an existing tool. RePaint uses resampling for image reconstruction [38], Restart studies adding noise followed by reverse integration [39], and RePS extends restart-based sampling to inverse problems [40]. Their results motivate including such operations in comparisons but do not establish which correction is appropriate after a particular new observation in trajectory forecasting.

2.5 Research direction

The reviewed studies already offer streaming generation, forecast reuse, and accelerated sampling. I therefore do not frame the problem as creating the first method that incorporates new observations. I investigate how these strategies behave when context changes within unfinished trajectory generation and how their applicability depends on observation arrival time, the extent of forecast change, and the available budget. The comparison must consider accuracy, uncertainty preservation, and update latency. Based on identified limitations, I will propose possible improvements; the particular approach and its distinction from the closest methods will be determined through further analysis and experiments.

Список литературы

- [1] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising Diffusion Probabilistic Models, 2020. URL <https://arxiv.org/abs/2006.11239>.
- [2] Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-Based Generative Modeling through Stochastic Differential Equations, 2020. URL <https://arxiv.org/abs/2011.13456>.
- [3] Tianpei Gu, Guangyi Chen, Junlong Li, Chunze Lin, Yongming Rao, Jie Zhou, and Jiwen Lu. Stochastic Trajectory Prediction via Motion Indeterminacy Diffusion, 2022. URL <https://arxiv.org/abs/2203.13777>.
- [4] Weibo Mao, Chenxin Xu, Qi Zhu, Siheng Chen, and Yanfeng Wang. Leapfrog Diffusion Model for Stochastic Trajectory Prediction, 2023. URL <https://arxiv.org/abs/2303.10895>.
- [5] Chiyu Max Jiang, Andre Cornman, Cheolho Park, Ben Sapp, Yin Zhou, and Dragomir Anguelov. MotionDiffuser: Controllable Multi-Agent Motion Prediction using Diffusion, 2023. URL <https://arxiv.org/abs/2306.03083>.
- [6] Yuanshao Zhu, Yongchao Ye, Shiyao Zhang, Xiangyu Zhao, and James J. Q. Yu. DiffTraj: Generating GPS Trajectory with Diffusion Probabilistic Model, 2023. URL <https://arxiv.org/abs/2304.11582>.
- [7] Michael Janner, Yilun Du, Joshua B. Tenenbaum, and Sergey Levine. Planning with Diffusion for Flexible Behavior Synthesis, 2022. URL <https://arxiv.org/abs/2205.09991>.
- [8] Anurag Ajay, Yilun Du, Abhi Gupta, Joshua Tenenbaum, Tommi Jaakkola, and Pulkit Agrawal. Is Conditional Generative Modeling all you need for Decision-Making?, 2022. URL <https://arxiv.org/abs/2211.15657>.
- [9] Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion, 2023. URL <https://arxiv.org/abs/2303.04137>.
- [10] Yinan Zheng, Ruiming Liang, Kexin Zheng, Jinliang Zheng, Liyuan Mao, Jianxiong Li, Weihao Gu, Rui Ai, Shengbo Eben Li, Xianyu Zhan, and Jingjing Liu. Diffusion-Based Planning for Autonomous Driving with Flexible Guidance, 2025. URL <https://arxiv.org/abs/2501.15564>.
- [11] Long Wei, Peiyan Hu, Ruiqi Feng, Haodong Feng, Yixuan Du, Tao Zhang, Rui Wang, Yue Wang, Zhi-Ming Ma, and Tailin Wu. DiffPhyCon: A Generative Approach to Control Complex Physical Systems, 2024. URL <https://arxiv.org/abs/2407.06494>.
- [12] Zhixuan Liang, Yao Mu, Mingyu Ding, Fei Ni, Masayoshi Tomizuka, and Ping Luo. AdaptDiffuser: Diffusion Models as Adaptive Self-evolving Planners, 2023. URL <https://arxiv.org/abs/2302.01877>.
- [13] Sigmund H. Høeg, Yilun Du, and Olav Egeland. Streaming Diffusion Policy: Fast Policy Synthesis with Variable Noise Diffusion Models, 2024. URL <https://arxiv.org/abs/2406.04806>.
- [14] Long Wei, Haodong Feng, Yuchen Yang, Ruiqi Feng, Peiyan Hu, Xiang Zheng, Tao Zhang, Dixia Fan, and Tailin Wu. CL-DiffPhyCon: Closed-loop Diffusion Control of Complex Physical Systems, 2024. URL <https://arxiv.org/abs/2408.03124>.
- [15] Boyuan Chen, Diego Marti Monso, Yilun Du, Max Simchowitz, Russ Tedrake, and Vincent Sitzmann. Diffusion Forcing: Next-token Prediction Meets Full-Sequence Diffusion, 2024. URL <https://arxiv.org/abs/2407.01392>.
- [16] Yufei Duan, Hang Yin, and Danica Kragic. Real-Time Iteration Scheme for Diffusion Policy, 2025. URL <https://arxiv.org/abs/2508.05396>.

- [17] Yinan Huang, Hans Hao-Hsun Hsu, Junran Wang, Bo Dai, and Pan Li. Accelerated Sequential Flow Matching: A Bayesian Filtering Perspective, 2026. URL <https://arxiv.org/abs/2602.05319>.
- [18] Kevin Black, Manuel Y. Galliker, and Sergey Levine. Real-Time Execution of Action Chunking Flow Policies, 2025. URL <https://arxiv.org/abs/2506.07339>.
- [19] Han Xue, Jieji Ren, Wendi Chen, Gu Zhang, Yuan Fang, Guoying Gu, Huazhe Xu, and Cewu Lu. Reactive Diffusion Policy: Slow-Fast Visual-Tactile Policy Learning for Contact-Rich Manipulation, 2025. URL <https://arxiv.org/abs/2503.02881>.
- [20] Lifeng Zhuo, Wendi Chen, Han Xue, Shirun Tang, Jun Lv, Cewu Lu, and Chuan Wen. FA-RDP: A Frequency-Adaptive Reactive Diffusion Policy for Contact-Rich Manipulation, 2026. URL <https://arxiv.org/abs/2607.28596>.
- [21] Yusuke Tashiro, Jiaming Song, Yang Song, and Stefano Ermon. CSDI: Conditional Score-based Diffusion Models for Probabilistic Time Series Imputation, 2021. URL <https://arxiv.org/abs/2107.03502>.
- [22] Juan Miguel Lopez Alcaraz and Nils Strodthoff. Diffusion-based Time Series Imputation and Forecasting with Structured State Space Models, 2022. URL <https://arxiv.org/abs/2208.09399>.
- [23] Kashif Rasul, Calvin Seward, Ingmar Schuster, and Roland Vollgraf. Autoregressive Denoising Diffusion Models for Multivariate Probabilistic Time Series Forecasting, 2021. URL <https://arxiv.org/abs/2101.12072>.
- [24] Lifeng Shen and James Kwok. Non-autoregressive Conditional Diffusion Models for Time Series Prediction, 2023. URL <https://arxiv.org/abs/2306.05043>.
- [25] Marcel Kollovich, Abdul Fatir Ansari, Michael Bohlke-Schneider, Jasper Zschiegner, Hao Wang, and Yuyang Wang. Predict, Refine, Synthesize: Self-Guiding Diffusion Models for Probabilistic Time Series Forecasting, 2023. URL <https://arxiv.org/abs/2307.11494>.
- [26] François Rozet and Gilles Louppe. Score-based Data Assimilation, 2023. URL <https://arxiv.org/abs/2306.10574>.
- [27] Bahjat Kavar, Michael Elad, Stefano Ermon, and Jiaming Song. Denoising Diffusion Restoration Models, 2022. URL <https://arxiv.org/abs/2201.11793>.
- [28] Hyungjin Chung, Jeongsol Kim, Michael T. McCann, Marc L. Klasky, and Jong Chul Ye. Diffusion Posterior Sampling for General Noisy Inverse Problems, 2022. URL <https://arxiv.org/abs/2209.14687>.
- [29] Jonathan Ho and Tim Salimans. Classifier-Free Diffusion Guidance, 2022. URL <https://arxiv.org/abs/2207.12598>.
- [30] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising Diffusion Implicit Models, 2020. URL <https://arxiv.org/abs/2010.02502>.
- [31] Cheng Lu, Yuhao Zhou, Fan Bao, Jianfei Chen, Chongxuan Li, and Jun Zhu. DPM-Solver: A Fast ODE Solver for Diffusion Probabilistic Model Sampling in Around 10 Steps, 2022. URL <https://arxiv.org/abs/2206.00927>.
- [32] Cheng Lu, Yuhao Zhou, Fan Bao, Jianfei Chen, Chongxuan Li, and Jun Zhu. DPM-Solver++: Fast Solver for Guided Sampling of Diffusion Probabilistic Models, 2022. URL <https://arxiv.org/abs/2211.01095>.
- [33] Wenliang Zhao, Lujia Bai, Yongming Rao, Jie Zhou, and Jiwen Lu. UniPC: A Unified Predictor-Corrector Framework for Fast Sampling of Diffusion Models, 2023. URL <https://arxiv.org/abs/2302.04867>.

- [34] Tero Karras, Miika Aittala, Timo Aila, and Samuli Laine. Elucidating the Design Space of Diffusion-Based Generative Models, 2022. URL <https://arxiv.org/abs/2206.00364>.
- [35] Tim Salimans and Jonathan Ho. Progressive Distillation for Fast Sampling of Diffusion Models, 2022. URL <https://arxiv.org/abs/2202.00512>.
- [36] Yang Song, Prafulla Dhariwal, Mark Chen, and Ilya Sutskever. Consistency Models, 2023. URL <https://arxiv.org/abs/2303.01469>.
- [37] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow Matching for Generative Modeling, 2022. URL <https://arxiv.org/abs/2210.02747>.
- [38] Andreas Lugmayr, Martin Danelljan, Andres Romero, Fisher Yu, Radu Timofte, and Luc Van Gool. RePaint: Inpainting using Denoising Diffusion Probabilistic Models, 2022. URL <https://arxiv.org/abs/2201.09865>.
- [39] Yilun Xu, Mingyang Deng, Xiang Cheng, Yonglong Tian, Ziming Liu, and Tommi Jaakkola. Restart Sampling for Improving Generative Processes, 2023. URL <https://arxiv.org/abs/2306.14878>.
- [40] Bilal Ahmed and Joseph G. Makin. Solving Diffusion Inverse Problems with Restart Posterior Sampling, 2025. URL <https://arxiv.org/abs/2511.20705>.