
Адаптивное условное диффузионное сэмплирование при поступлении новых наблюдений в процессе генерации

Аннотация

Данная работа посвящена исследованию способов адаптации диффузионных моделей для генерации траекторий к условиям, когда новый контекст поступает во время генерации. В задачах прогнозирования движения дополнительные наблюдения могут уточнить возможные варианты будущего или существенно изменить их вероятности, однако учёт этих данных может потребовать повторных вычислений, которые не всегда допустимы при ограниченном времени и вычислительном бюджете. Я исследую, как обновлять формируемую траекторию с учётом новых данных, в каких случаях можно использовать уже выполненные вычисления и как выбранный способ обновления влияет на качество прогноза и затраты на его получение. Для этого я рассмотрю существующие подходы к диффузионному прогнозированию, потоковой генерации и условному сэмплированию, сопоставлю их предположения и ограничения и выделю способы, применимые к изменению контекста внутри незавершённого процесса генерации. Сравнение предполагается проводить при разных моментах поступления наблюдений, разной степени их влияния на прогноз и сопоставимых вычислительных бюджетах, учитывая точность траекторий, разнообразие возможных исходов и время получения обновлённого результата. При этом я отдельно рассмотрю качество вероятностного прогноза, поскольку близость одной сгенерированной траектории к наблюдаемому движению ещё не означает, что модель корректно отражает неопределённость будущего. На основе выявленных ограничений я предложу возможные способы улучшения существующих подходов и проверю, в каких условиях они позволяют эффективнее использовать новые наблюдения. Исследование направлено на определение возможностей и границ адаптации диффузионного сэмплирования к изменяющемуся контексту при ограниченных вычислительных ресурсах.

Ключевые слова: диффузионные модели; генерация траекторий; вероятностное прогнозирование; условное сэмплирование; потоковые наблюдения; вычислительная эффективность.

1 Обзор литературы

1.1 Диффузионная генерация и прогнозирование траекторий

Диффузионные модели формируют результат через последовательное расшумление. Базовая дискретная формулировка представлена в DDPM [1], а непрерывная связь между стохастическим процессом и дифференциальным уравнением — в Score-SDE [2]. Для моей темы важно, что между начальным шумом и готовой траекторией существует промежуточное состояние. При поступлении новых данных возникает вопрос, можно ли использовать это состояние для обновлённого прогноза и какие ошибки при этом появляются.

В прогнозировании движения MID использует историю траекторий и взаимодействия участников для условной генерации [3]. LED дополнительно обучает инициализацию, позволяющую пропускать часть расшумления [4], а MotionDiffuser моделирует совместные варианты движения нескольких участников и поддерживает направленное сэмплирование [5]. Эти работы дают предметную основу для сравнения качества, разнообразия и стоимости прогнозов. DiffTraj также работает с траекториями, но решает задачу генерации синтетических GPS-данных [6]. Поэтому я рассматриваю её как источник идей о представлении данных, а не как прямой аналог обновления прогноза.

Отдельную группу составляют методы планирования. Diffuser и Decision Diffuser используют условную генерацию для построения поведения с заданными целями и ограничениями [7], [8]. Diffusion Policy генерирует последовательности действий по наблюдениям [9]; Diffusion Planner рассматривает автономное движение [10], а DiffPhyCon — управление физическими системами [11]. Здесь качество определяется не только соответствием распределению данных, но и результатом исполнения выбранных действий. AdaptDiffuser дополнительно изменяет сам планировщик через дообучение на отобранных синтетических данных [12]. Я отделяю такую адаптацию модели от обновления одного незавершённого прогноза.

1.2 Новые наблюдения и повторное использование вычислений

Наиболее близки к теме работы, сохраняющие часть генерации между поступлениями данных. Streaming Diffusion Policy поддерживает буфер действий с разными уровнями шума и уточняет его по новым наблюдениям [13]. CL-DiffPhyCon также использует асинхронное расшумление, включая обратную связь при генерации дальнейших управляющих воздействий [14]. Они показывают, что использование нового контекста до завершения всей последовательности уже является самостоятельным направлением исследований. Diffusion Forcing даёт более общий механизм обучения последовательностей с разными уровнями шума у элементов [15].

RTI-DP использует ранее предсказанную последовательность как начальное приближение для следующего расчёта [16]. Sequential Flow Matching рассматривает перенос предыдущего распределения в обновлённое по наблюдениям [17]. В отличие от повторного использования отдельной траектории, здесь обучается переход между распределениями. Авторы последней работы отмечают накопление ошибок при рекурсивных обновлениях и обсуждают адаптивное повторное зашумление и перезапуск как дальнейшие направления. Это конкретная связь с моей темой, но не основание считать такую общую идею новой.

Задержку можно учитывать и на уровне исполнения. RTC согласует соседние фрагменты действий при асинхронной генерации [18]. Reactive Diffusion Policy выделяет быстрый контур обратной связи [19], а FA-RDP адаптирует частоту вывода и число шагов генерации к неоднозначности действий [20]. Эти подходы показывают, что реакция на новые данные может достигаться разными механизмами. Поэтому я буду различать обновление промежуточного сэмпла, перенос готового прогноза и коррекцию исполнения: близкие практические цели не делают эти задачи одинаковыми.

1.3 Условное распределение по наблюдениям

Для анализа обновлений полезны работы с временными рядами. CSDI и SSSD восстанавливают пропущенные значения по доступным наблюдениям [21], [22]. TimeGrad строит авторегрессионный прогноз [23], а TimeDiff генерирует будущий участок совместно и использует специальные механизмы задания условия [24]. TSDiff вводит условия при выводе и рассматривает уточнение готовых прогнозов [25]. Эти методы помогают выбрать основу для экспериментов, но применение к наблюдениям, поступающим внутри расшумления, требует собственного протокола.

Score-based Data Assimilation отделяет модель наблюдений от обучения генератора и восстанавливает траектории по неполным или шумным измерениям [26]. В обратных задачах похожую роль играют DDRM и Diffusion Posterior Sampling [27], [28]. Однако согласование с измерениями может опираться на приближения, а ограничения линейной модели наблюдений подходят не для любого контекста. Кроме того, Classifier-Free Guidance управляет соответствием условию и разнообразием [29]; усиление такого соответствия само по себе не подтверждает корректность вероятностного обновления.

1.4 Вычислительная эффективность и повторное зашумление

Сокращение затрат не обязательно связано с адаптацией контекста. DDIM, DPM-Solver, DPM-Solver++ и UniPC ускоряют численное сэмплирование [30], [31], [32], [33]. EDM систематизирует выбор параметризации, расписания шума и сэмплера [34]. Progressive Distillation и Consistency Models уменьшают число шагов через изменение обучения [35], [36], а Flow Matching представляет смежный способ обучать перенос распределений [37]. Эти работы нужны, чтобы отделить возможную пользу обновления контекста от обычного ускорения генератора и учитывать стоимость дополнительного обучения.

Повторное зашумление также является известным инструментом. RePaint использует повторное сэмплирование при восстановлении изображений [38], Restart исследует сочетание добавления шума и обратного интегрирования [39], а RePS переносит restart-подход на обратные задачи [40]. Их результаты обосновывают включение подобных операций в сравнение, но не устанавливают, какая коррекция нужна после конкретного нового наблюдения в задаче траекторий.

1.5 Направление исследования

Рассмотренные работы уже предлагают способы потоковой генерации, повторного использования прогнозов и ускорения сэмплирования. Поэтому я не формулирую задачу как создание первого метода, учитывающего новые наблюдения. Я исследую, как эти способы работают при изменении контекста внутри незавершённой генерации траектории и как их применимость зависит от момента поступления данных, величины изменения прогноза и доступного бюджета. Для сравнения важны и точность, и сохранение неопределённости, и время получения обновления. На основе выявленных ограничений я предложу возможные улучшения; конкретный подход и его отличие от ближайших методов будут определены по результатам дальнейшего анализа и экспериментов.

Список литературы

- [1] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising Diffusion Probabilistic Models, 2020. URL <https://arxiv.org/abs/2006.11239>.
- [2] Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-Based Generative Modeling through Stochastic Differential Equations, 2020. URL <https://arxiv.org/abs/2011.13456>.
- [3] Tianpei Gu, Guangyi Chen, Junlong Li, Chunze Lin, Yongming Rao, Jie Zhou, and Jiwen Lu. Stochastic Trajectory Prediction via Motion Indeterminacy Diffusion, 2022. URL <https://arxiv.org/abs/2203.13777>.
- [4] Weibo Mao, Chenxin Xu, Qi Zhu, Siheng Chen, and Yanfeng Wang. Leapfrog Diffusion Model for Stochastic Trajectory Prediction, 2023. URL <https://arxiv.org/abs/2303.10895>.
- [5] Chiyu Max Jiang, Andre Cornman, Cheolho Park, Ben Sapp, Yin Zhou, and Dragomir Anguelov. MotionDiffuser: Controllable Multi-Agent Motion Prediction using Diffusion, 2023. URL <https://arxiv.org/abs/2306.03083>.
- [6] Yuanshao Zhu, Yongchao Ye, Shiyao Zhang, Xiangyu Zhao, and James J. Q. Yu. DiffTraj: Generating GPS Trajectory with Diffusion Probabilistic Model, 2023. URL <https://arxiv.org/abs/2304.11582>.
- [7] Michael Janner, Yilun Du, Joshua B. Tenenbaum, and Sergey Levine. Planning with Diffusion for Flexible Behavior Synthesis, 2022. URL <https://arxiv.org/abs/2205.09991>.
- [8] Anurag Ajay, Yilun Du, Abhi Gupta, Joshua Tenenbaum, Tommi Jaakkola, and Pulkit Agrawal. Is Conditional Generative Modeling all you need for Decision-Making?, 2022. URL <https://arxiv.org/abs/2211.15657>.
- [9] Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion, 2023. URL <https://arxiv.org/abs/2303.04137>.
- [10] Yinan Zheng, Ruiming Liang, Kexin Zheng, Jinliang Zheng, Liyuan Mao, Jianxiong Li, Weihao Gu, Rui Ai, Shengbo Eben Li, Xianyu Zhan, and Jingjing Liu. Diffusion-Based Planning for Autonomous Driving with Flexible Guidance, 2025. URL <https://arxiv.org/abs/2501.15564>.
- [11] Long Wei, Peiyan Hu, Ruiqi Feng, Haodong Feng, Yixuan Du, Tao Zhang, Rui Wang, Yue Wang, Zhi-Ming Ma, and Tailin Wu. DiffPhyCon: A Generative Approach to Control Complex Physical Systems, 2024. URL <https://arxiv.org/abs/2407.06494>.
- [12] Zhixuan Liang, Yao Mu, Mingyu Ding, Fei Ni, Masayoshi Tomizuka, and Ping Luo. AdaptDiffuser: Diffusion Models as Adaptive Self-evolving Planners, 2023. URL <https://arxiv.org/abs/2302.01877>.
- [13] Sigmund H. Høeg, Yilun Du, and Olav Egeland. Streaming Diffusion Policy: Fast Policy Synthesis with Variable Noise Diffusion Models, 2024. URL <https://arxiv.org/abs/2406.04806>.
- [14] Long Wei, Haodong Feng, Yuchen Yang, Ruiqi Feng, Peiyan Hu, Xiang Zheng, Tao Zhang, Dixia Fan, and Tailin Wu. CL-DiffPhyCon: Closed-loop Diffusion Control of Complex Physical Systems, 2024. URL <https://arxiv.org/abs/2408.03124>.
- [15] Boyuan Chen, Diego Marti Monso, Yilun Du, Max Simchowitz, Russ Tedrake, and Vincent Sitzmann. Diffusion Forcing: Next-token Prediction Meets Full-Sequence Diffusion, 2024. URL <https://arxiv.org/abs/2407.01392>.
- [16] Yufei Duan, Hang Yin, and Danica Kragic. Real-Time Iteration Scheme for Diffusion Policy, 2025. URL <https://arxiv.org/abs/2508.05396>.

- [17] Yinan Huang, Hans Hao-Hsun Hsu, Junran Wang, Bo Dai, and Pan Li. Accelerated Sequential Flow Matching: A Bayesian Filtering Perspective, 2026. URL <https://arxiv.org/abs/2602.05319>.
- [18] Kevin Black, Manuel Y. Galliker, and Sergey Levine. Real-Time Execution of Action Chunking Flow Policies, 2025. URL <https://arxiv.org/abs/2506.07339>.
- [19] Han Xue, Jieji Ren, Wendi Chen, Gu Zhang, Yuan Fang, Guoying Gu, Huazhe Xu, and Cewu Lu. Reactive Diffusion Policy: Slow-Fast Visual-Tactile Policy Learning for Contact-Rich Manipulation, 2025. URL <https://arxiv.org/abs/2503.02881>.
- [20] Lifeng Zhuo, Wendi Chen, Han Xue, Shirun Tang, Jun Lv, Cewu Lu, and Chuan Wen. FA-RDP: A Frequency-Adaptive Reactive Diffusion Policy for Contact-Rich Manipulation, 2026. URL <https://arxiv.org/abs/2607.28596>.
- [21] Yusuke Tashiro, Jiaming Song, Yang Song, and Stefano Ermon. CSDI: Conditional Score-based Diffusion Models for Probabilistic Time Series Imputation, 2021. URL <https://arxiv.org/abs/2107.03502>.
- [22] Juan Miguel Lopez Alcaraz and Nils Strodthoff. Diffusion-based Time Series Imputation and Forecasting with Structured State Space Models, 2022. URL <https://arxiv.org/abs/2208.09399>.
- [23] Kashif Rasul, Calvin Seward, Ingmar Schuster, and Roland Vollgraf. Autoregressive Denoising Diffusion Models for Multivariate Probabilistic Time Series Forecasting, 2021. URL <https://arxiv.org/abs/2101.12072>.
- [24] Lifeng Shen and James Kwok. Non-autoregressive Conditional Diffusion Models for Time Series Prediction, 2023. URL <https://arxiv.org/abs/2306.05043>.
- [25] Marcel Kollovich, Abdul Fatir Ansari, Michael Bohlke-Schneider, Jasper Zschiegner, Hao Wang, and Yuyang Wang. Predict, Refine, Synthesize: Self-Guiding Diffusion Models for Probabilistic Time Series Forecasting, 2023. URL <https://arxiv.org/abs/2307.11494>.
- [26] François Rozet and Gilles Louppe. Score-based Data Assimilation, 2023. URL <https://arxiv.org/abs/2306.10574>.
- [27] Bahjat Kavar, Michael Elad, Stefano Ermon, and Jiaming Song. Denoising Diffusion Restoration Models, 2022. URL <https://arxiv.org/abs/2201.11793>.
- [28] Hyungjin Chung, Jeongsol Kim, Michael T. McCann, Marc L. Klasky, and Jong Chul Ye. Diffusion Posterior Sampling for General Noisy Inverse Problems, 2022. URL <https://arxiv.org/abs/2209.14687>.
- [29] Jonathan Ho and Tim Salimans. Classifier-Free Diffusion Guidance, 2022. URL <https://arxiv.org/abs/2207.12598>.
- [30] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising Diffusion Implicit Models, 2020. URL <https://arxiv.org/abs/2010.02502>.
- [31] Cheng Lu, Yuhao Zhou, Fan Bao, Jianfei Chen, Chongxuan Li, and Jun Zhu. DPM-Solver: A Fast ODE Solver for Diffusion Probabilistic Model Sampling in Around 10 Steps, 2022. URL <https://arxiv.org/abs/2206.00927>.
- [32] Cheng Lu, Yuhao Zhou, Fan Bao, Jianfei Chen, Chongxuan Li, and Jun Zhu. DPM-Solver++: Fast Solver for Guided Sampling of Diffusion Probabilistic Models, 2022. URL <https://arxiv.org/abs/2211.01095>.
- [33] Wenliang Zhao, Lujia Bai, Yongming Rao, Jie Zhou, and Jiwen Lu. UniPC: A Unified Predictor-Corrector Framework for Fast Sampling of Diffusion Models, 2023. URL <https://arxiv.org/abs/2302.04867>.

- [34] Tero Karras, Miika Aittala, Timo Aila, and Samuli Laine. Elucidating the Design Space of Diffusion-Based Generative Models, 2022. URL <https://arxiv.org/abs/2206.00364>.
- [35] Tim Salimans and Jonathan Ho. Progressive Distillation for Fast Sampling of Diffusion Models, 2022. URL <https://arxiv.org/abs/2202.00512>.
- [36] Yang Song, Prafulla Dhariwal, Mark Chen, and Ilya Sutskever. Consistency Models, 2023. URL <https://arxiv.org/abs/2303.01469>.
- [37] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow Matching for Generative Modeling, 2022. URL <https://arxiv.org/abs/2210.02747>.
- [38] Andreas Lugmayr, Martin Danelljan, Andres Romero, Fisher Yu, Radu Timofte, and Luc Van Gool. RePaint: Inpainting using Denoising Diffusion Probabilistic Models, 2022. URL <https://arxiv.org/abs/2201.09865>.
- [39] Yilun Xu, Mingyang Deng, Xiang Cheng, Yonglong Tian, Ziming Liu, and Tommi Jaakkola. Restart Sampling for Improving Generative Processes, 2023. URL <https://arxiv.org/abs/2306.14878>.
- [40] Bilal Ahmed and Joseph G. Makin. Solving Diffusion Inverse Problems with Restart Posterior Sampling, 2025. URL <https://arxiv.org/abs/2511.20705>.